

Analiza danych Spotify

Projekt z przedmiotu Przetwarzanie Danych Ustrukturyzowanych

Kacper Pawiński i Aleksander Sergiej


Politechnika Warszawska

14 czerwca 2026

Plan prezentacji

- 1 Pipeline Projektu
- 2 Analiza popularności
- 3 Analiza audio gatunków
- 4 Jak radzi sobie K-means?
- 5 Dodatek
- 6 Podsumowanie

Architektura Pipeline'u



Rysunek 1: Przepływ przetwarzania danych: od surowych plików po wyniki końcowe.

Analiza popularności

Aby wyłonić „prawdziwych” artystów jednego przeboju, wprowadziliśmy wskaźnik **GAP**:

$$GAP = \max(P) - \text{mediana}(P \setminus \{\max(P)\}) \quad (1)$$


gdzie P to zbiór wartości popularności wszystkich utworów danego artysty.

Charakterystyka

- Wysoki **GAP** wskazuje na artystę, którego jeden utwór drastycznie odbiega popularnością od reszty katalogu.
- Alternatywny wskaźnik $Ratio = \frac{\max(P)}{\text{mediana}(P_{rest})}$.


Top 10 One-Hit Wonders (wskaźnik GAP)

- Ranking prezentuje artystów z największą różnicą między ich największym hitem a resztą dorobku.
- Dodatkowo dodajemy najpopularniejszych artystów.



Rysunek 2: Liderzy rankingu One-Hit Wonder wg wskaźnika GAP.

Popularność w zależności od gatunku




Rysunek 3: Rozkład popularności dla wybranych, różnorodnych gatunków.

- Box plot pokazuje wariancję popularności wewnątrz gatunku.
- Uwzględniono gatunki o skrajnie różnych profilach

Analiza audio gatunków


Nastrój (Valence) a Gatunki



- **Valence:** Indeks pozytywności utworu (0.0 - 1.0).
- Gatunki taneczne i latynoskie zazwyczaj osiągają najwyższe wyniki.


Rysunek 4: Gatunki o najwyższej średniej Valence („najweselsze”).

Treści wulgarne (Explicit Content)



Rysunek 5: Udział utworów explicit w wybranych gatunkach.

Profile Audio Gatunków




Rysunek 6: Wykres radarowy dla wybranych gatunków (Pop vs Metal vs Jazz).

Jak radzi sobie K-means?





Optymalna liczba grup w K-means

- Wybór optymalnej liczby klastrow k .
- Analiza sumy kwadratów wewnątrz klastrow (WSS).
- Wybrano optymalne k , gdzie spadek WSS spowalnia.




Rysunek 7: Wybór k

Wyniki K-means: Grupowanie gatunków




Dodatek

Porównanie: Kacper vs Aleksander




Rysunek 9: Ulubione gatunki Kacpra



Rysunek 10: Ulubione gatunki Aleksandra

Audio Profile: Kacper vs Aleksander



Rysunek 11: Porównanie średnich cech audio polubionych piosenek.

- Na przykładzie rock'a świetnie widać jak popularność niektórych utworów się różni od drugih.
- Klasteryzacja K-means pozwala na odkrycie "rodzin" gatunków (np. gatunki akustyczne vs elektroniczne).
- Analiza indywidualnych danych była bardzo zabawna. Ktoś mógł podmienić jeden swój popularny gatunek.

- Maharshi Pandya. (2022). Spotify Tracks Dataset [Data set]. Kaggle. <https://doi.org/10.34740/KAGGLE/DSV/4372070>
- Licencja: <https://opendatacommons.org/licenses/odbl/1-0/>.